



تمرین سری سوم دوره مبانی یادگیری ماشین و شبکه های عصبی

عنوان تمرین: پیاده سازی رگرسیون خطی چندگانه و رگرسیون غیرخطی تک متغیره

دیتاست:

فایل CSV دیتاست و توضیحات کامل فیچرها و خروجی در پیوست این فایل ارسال شده است؛ به طور کلی باید با استفاده از رگرسیون و فیچرهای مشخص دیتا، امید به زندگی یک کشور پیش بینی شود.

بخش اول: پیاده سازی رگرسیون خطی چندگانه

توضیحات:

در این بخش باید مدل رگرسیون چندگانه خود را بدون استفاده از کتابخانه های پیشرفته پیاده سازی کنید. در این بخش، مدل باید بدون استفاده از حلقه for و تنها با استفاده از vectorization پیاده سازی شود.

آماده سازی و پیش پردازش داده ها:

دیتاست داده شده را دریافت کرده و بررسی اولیه روی داده ها انجام دهید و ویژگی های کیفی (Categorical Features) موجود در دیتاست را با استفاده از روش های مناسب (مانند One-Hot Encoding یا Label Encoding یا غیره) به مقادیر عددی تبدیل کنید؛ اگر دیتا ست دارای مقادیر NaN است آنها را با مقادیر مناسب پر کنید. اگر فیچری از فیچرهای داده شده به نظر شما تاثیری در دقیق تر کردن خروجی مدل شما ندارد میتوانید آن را حذف کنید، این موضوع را با تست بررسی کنید. توجه داشته باشید که دیتا تاثیر بسزایی در عملکرد مدل شما دارد. داده های خود را به دو بخش train و test تقسیم بندی کنید، سهم هر بخش دلخواه است اما میتواند یک پنجم دیتا را برای بخش test و چهار پنجم دیتا را برای بخش train در نظر بگیرید.

پیاده سازی مدل رگرسیون خطی چندگانه:

نکته: استفاده از حلقه *for* در هیچ یک از مراحل این بخش از تمرین مجاز نیست.

مرحله اول: نوشتن معادله و محاسبه y_{pred}

ابتدا باید تابعی خطی به عنوان معادله مدل خود بر اساس تعداد فیچرهای دیتاست با ضرایب w به همراه یک ضریب b ثابت بنویسید. سپس y_{pred} را با استفاده از جایگذاری مقادیر فیچرها در معادله بدست آورید و در یک آرایه قرار دهید.

مرحله دوم: محاسبه تابع هزینه (Cost Function (J)

برای بدست آوردن ضرایب w و مقدار ثابت b نیاز است که تابع هزینه را به صورت جمع توان دوی ارورها همانند مطالب تدریس شده بنویسید. (در نهایت جمع کرده و بر دو برابر تعداد دیتا تقسیم کنید.)

مرحله سوم: محاسبه گرادیان

برای بدست آوردن مقدار ضرایب و مشخص کردن مقدار دقیق معادله مدل، نیاز است که در این بخش، مشتق تابع هزینه را نسبت به هر یک از ضرایب w محاسبه کنید. در نهایت تابع باید دو ماتریس از مشتق های تابع هزینه نسبت به w و b خروجی دهد.

مرحله چهارم: محاسبه گرادیان نزولی

پس از محاسبه گرادیان، حال باید مقادیر w و b بروزرسانی شوند. بر اساس فرمول گرادیان و انتخاب نرخ یادگیری مناسب، این بخش را به صورت تفریق ماتریس ها انجام دهید و ضرایب مذکور را بروزرسانی کنید. در نهایت ضرایبی باید به عنوان ضرایب نهایی انتخاب شوند که مقدار مشتق در آنها کمترین است. در پیاده سازی گام های فرایند لرنینگ میتوانید از حلقه *for* استفاده کنید.

ارزیابی عملکرد مدل:

در این مرحله باید با استفاده از یکی از روش های ارزیابی مدل (MSE, RMSE, MAE) و بررسی بر قسمت *test* دیتا، عملکرد مدل خود را بسنجید.

بخش دوم: پیاده سازی رگرسیون غیرخطی تک متغیره

نکته: در این بخش از تمرین استفاده از حلقه *for* مجاز است.

توضیحات:

به طور کلی در مسائل رگرسیون، باید بهترین مدلی که بر روی دیتای train فیت میشود را پیدا کرد که دیتا را ارائه دهد و همچنین بهترین عملکرد را برای پیش بینی خروجی ورودی جدید داشته باشد. در این بخش به جای پیدا کردن معادله ای خطی، دیتا را با معادله ای غیرخطی ترسیم میکنیم که عملکرد مدل دقیق تر باشد. تک متغیره بودن بدین منظور است که تصور میکنیم خروجی فقط به همان یک فیچر وابسته است. (تنها یک X داریم).

آماده سازی و پیش پردازش داده ها:

یکی از فیچر های (ستون های) غیر کتگوریکال دیتاست را انتخاب کرده و بر اساس آن مدل خود را پیاده سازی کنید. توجه داشته باشید که تغییر فیچر میتواند عملکرد مدل را بهبود ببخشد. همانند بخش قبل باید داده های NaN را با مقادیر مناسب پر کنید. لازم به ذکر است تقسیم داده ها به دو قسمت train و test نیز ضروری است. توجه بفرمایید که خروجی شما (Y) همان امید به زندگی میباشد.

پیاده سازی رگرسیون غیرخطی تک متغیره:

مرحله یک: ایجاد معادله مدل

ابتدا فیچر (X) و خروجی (Y) دیتای train را نمایش داده و با توجه به شکل پراکندگی داده ها مناسب ترین تابع غیر خطی را انتخاب کنید. (توابع چند جمله ای درجه دو، سه، چهار و پنج). سپس معادله خود را بنویسید و بر روی دیتا فیت کنید، منظور این است که باید ورودی های فیچر انتخاب شده قسمت train را به معادله داده و مقدار خروجی پیش بینی شده (y_{pred}) را حساب کنید.

مرحله دو: نوشتن تابع هزینه (Cost Function (J))

در این مرحله ابتدا تابع هزینه را به صورت جمع توان دوی ارور ها بنویسید.

مرحله سوم: محاسبه تابع گرادیان

مشتق تابع هزینه را نسبت به هر یک از ضرایب (w) و مقدار ثابت (b) محاسبه کنید. این تابع باید دو خروجی dj_alpha و dj_beta را بدهد. که مشتقات تابع هزینه به ضرایب میباشد.

مرحله چهارم: محاسبه گرادیان نزولی

پس از محاسبه گرادیان، حال باید گرادیان نزولی را محاسبه کرد و سپس باید مقادیر ضرایب (w) و ضریب ثابت (b) را بروزرسانی کنید؛ سپس مقادیری که مشتق در آنها کمترین بود به عنوان ضرایب انتخاب میشوند.

ارزیابی عملکرد مدل:

در این مرحله باید با استفاده از یکی از روش های ارزیابی مدل (MSE , $RMSE$, MAE) و بررسی بر قسمت $test$ دیتا عملکرد مدل خود را بسنجید.

نکته:

در پیاده سازی معادله مدل، یکبار درجه معادله را زیاد انتخاب کنید برای مثال درجه پنج، سپس معادله خود را بر روی دیتای $train$ نمایش دهید. بار دیگر درجه چند جمله ای را پایین انتخاب کنید سپس مجدداً آن را نمایش دهید؛ از دو نمودار مشاهده شده چه نتیجه ای میگیرید؟ مشکل را شرح دهید و توضیح دهید برای حل آن باید چه کرد.