



تمرین سری چهارم دوره مبانی یادگیری ماشین و شبکه های عصبی

عنوان تمرین: پیاده سازی رگرسیون لجستیک

ویدیو های یادآوری:

با دیدن سه ویدیو قرار داده شده، خلاصه ای از هر کدام یادداشت و ارسال کنید.

• [StatQuest: Logistic Regression](#)

• [Machine Learning Fundamentals: Bias and Variance](#)

• [Regularization Part 1: Ridge \(L2\) Regression](#)

دیتاست:

دیتاست مورد استفاده شامل اطلاعات مربوط به ویروس کووید-۱۹ است. این اطلاعات شامل ویژگی های بالینی و جمعیت شناختی مانند سن، وجود بیماری های زمینه ای، و وضعیت زمانی علائم و ابتلا به بیماری کووید-۱۹ می باشد.

توضیحات:

هدف این تمرین، پیش بینی احتمال زنده ماندن بیماران مبتلا به کووید-۱۹ بر اساس ویژگی های ذکر شده آنهاست. این کار با استفاده از مدل رگرسیون لجستیک و تحلیل ویژگی های مشخص داده انجام می شود. این تمرین دارای دو بخش است که توضیحات هر بخش به ترتیب مراحل، ارائه شده است.

بخش اول: آموزش (train) اولیه و مشکل عدم توازن داده (Imbalanced Dataset)

نکته: استفاده از کتابخانه های یادگیری ماشین در هیچ یک از مراحل مجاز نیست!

آماده سازی و پیش پردازش داده ها:

دیتاست فایل covid.csv را بررسی کرده و تغییرات لازم را برای پاک سازی داده ها اعمال کنید. ابتدا مقادیر گمشده یا نامناسب (مانند مقادیر ۹-۹۹-۹۹۹۹ در ستون `date_died` نشان دهنده عدم فوت است و مقدار # در دیتا به معنای مقدار نامشخص است که باید از دیتا حذف شوند) را شناسایی و اصلاح کنید (باید ستون خروجی را به صورت ۰ و ۱ بسازید)؛ سپس ستون های (فیچر) غیرضروری یا نادرست را با تشخیص خود حذف کرده و اطمینان حاصل کنید که داده ها به صورت مناسب برای استفاده در مدل ماشین لرنینگ آماده شده اند. پس از این مرحله، داده ها را به دو بخش

آموزش (train) و آزمایش (test) تقسیم کنید؛ سپس داده های test خود را بر اساس مقدار خروجی (۰ یا ۱) را نیز به دو بخش تقسیم کنید.

پیاده سازی مدل رگرسیون لجستیک:

• تعریف تابع سیگموئید (Sigmoid Activation)

تابع سیگموئید به عنوان تابع فعال سازی در رگرسیون لجستیک استفاده می شود و پیش بینی هایی بین ۰ و ۱ ایجاد می کند؛ در این مرحله باید تابع سیگموئید را پیاده سازی کنید که برای پیش بینی مرگ و زندگی بر اساس بیماری کووید به کار می رود.

• محاسبه تابع هزینه (Cost Function Calculation)

هدف رگرسیون لجستیک کمینه کردن تابع هزینه است؛ در این مرحله باید تابع هزینه را پیاده سازی کنید که میزان خطای پیش بینی مدل را محاسبه کند.

• محاسبه گرادیان (Gradient Computation)

گرادیان تابع هزینه برای به روز رسانی پارامترهای مدل استفاده می شود؛ در این مرحله باید گرادیان تابع هزینه را محاسبه کرده تا بتوانید پارامترهای مدل را به روز رسانی کنید.

• بهینه سازی با گرادیان دسنت (Gradient Descent Optimization)

الگوریتم گرادیان نزولی برای به روز رسانی پارامترهای مدل استفاده می شود؛ در این مرحله باید از الگوریتم مذکور برای بهینه سازی پارامترها استفاده کنید. دقت کنید که نرخ یادگیری (α) باید به طور مناسب تنظیم شود.

• آموزش مدل (Model Training)

با استفاده از داده های آموزشی (train)، مدل خود را آموزش دهید؛ از الگوریتم گرادیان نزولی برای بهینه سازی پارامترها و کمینه کردن تابع هزینه استفاده کنید و پس از چندین دور (epoch) آموزش، مدل باید به پارامترهای بهینه ای برسد.

• ارزیابی و تحلیل عملکرد (Performance Evaluation and Analysis)

پس از آموزش مدل، عملکرد آن را ارزیابی کنید. برای ارزیابی، می توانید از معیارهای مختلفی مانند دقت (accuracy)، بازخوانی (recall)، دقت پیش بینی (precision) و F1-score استفاده کنید؛ عملکرد مدل خود را با استفاده از دو گروه تست (دو گروه تست با خروجی ۰ یا ۱ که در قسمت قبل جدا کردید) ارزیابی کنید و نتایج را با نمودارها و معیارهای مختلف نشان دهید. در این قسمت مشاهده خواهید کرد که عملکرد مدل در دو گروه تست مناسب نیست. این مشکل به دلیل غیرمتوازن بودن دیتا رخ میدهد، این بدان معناست که مقدار خروجی ها در ۰ و ۱ یکسان نیست به این مشکل اصطلاحاً Imbalanced Data میگویند. تا این جا شما مدل خود را با دیتای غیر متوازن آموزش داده اید و

همانطور که به آن رسیدید خواهید رسید، نتایج مطلوب نیستند. در قسمت بعد با استفاده از دیتاست فایل `balanced_dataset_covid.csv` همین مراحل طی خواهند شد. روش های بالانس نمودن دیتا را مطالعه کرده و راجع به کار با دیتای Imbalanced گزارشی در حد یک صفحه در غالب یک فایل pdf ارسال کنید.

بخش دوم: آموزش (train) با دیتای دارای توازن و Regularization

نکته: استفاده از کتابخانه های یادگیری ماشین در هیچ یک از مراحل مجاز نیست!

آماده سازی و پیش پردازش داده ها:

با استفاده از دیتاست موجود در فایل `balanced_dataset_covid.csv` تمام مراحل پیش پردازش دیتای قبلی را انجام دهید. (از جمله حذف فیچر، کار با دیتای NaN، ...). سپس به دو بخش `train` و `test` دیتا را تقسیم کرده و نیازی نیست دیتای `test` نیز به دو گروه تقسیم شود.

پیاده سازی مدل رگرسیون لجستیک:

- تعریف تابع سیگموید (Sigmoid Activation)

تابع سیگموید به عنوان تابع فعال سازی در رگرسیون لجستیک استفاده می شود و پیش بینی هایی بین ۰ و ۱ ایجاد می کند؛ در این مرحله باید تابع سیگموید را پیاده سازی کنید که برای پیش بینی مرگ و زندگی بر اساس بیماری کووید به کار می رود.

- محاسبه تابع هزینه (Cost Function Calculation)

هدف رگرسیون لجستیک کمینه کردن تابع هزینه است؛ در این مرحله باید تابع هزینه را پیاده سازی کنید که میزان خطای پیش بینی مدل را محاسبه کند.

- محاسبه گرادیان (Gradient Computation)

گرادیان تابع هزینه برای به روز رسانی پارامترهای مدل استفاده می شود؛ در این مرحله باید گرادیان تابع هزینه را محاسبه کرده تا بتوانید پارامترهای مدل را به روز رسانی کنید.

- بهینه سازی با گرادیان دسنت (Gradient Descent Optimization)

الگوریتم گرادیان نزولی برای به روز رسانی پارامترهای مدل استفاده می شود؛ در این مرحله باید از الگوریتم مذکور برای بهینه سازی پارامترها استفاده کنید. دقت کنید که نرخ یادگیری (α) باید به طور مناسب تنظیم شود.

- آموزش مدل (Model Training)

با استفاده از داده‌های آموزشی (train)، مدل خود را آموزش دهید؛ از الگوریتم گرادیان نزولی برای بهینه‌سازی پارامترها و کمینه کردن تابع هزینه استفاده کنید و پس از چندین دور (epoch) آموزش، مدل باید به پارامترهای بهینه‌ای برسد.

- ارزیابی و تحلیل عملکرد (Performance Evaluation and Analysis)

پس از آموزش مدل، عملکرد آن را ارزیابی کنید. برای ارزیابی، می‌توانید از معیارهای مختلفی مانند دقت (accuracy)، بازخوانی (recall)، دقت پیش‌بینی (precision) و F1-score استفاده کنید؛ عملکرد مدل خود را با استفاده از گروه تست ارزیابی کنید و نتایج را با نمودارها و معیارهای مختلف نشان دهید. اگر مدل شما عملکرد خوبی بر دیتای train دارد و عملکرد مناسبی بر دیتای test از خود نشان نمیدهد این بدان معناست که مدل اصطلاحاً overfit شده است. برای رفع این مشکل میتوان از Regularization استفاده کرد که دارای دو روش L1 و L2 میباشد.

نکته:

عملکرد مدل خود را پس از آموزش ارزیابی کنید و بررسی کنید که آیا استفاده از Regularization ضروری است یا خیر. اگر مدل به Regularization نیاز داشت، مشخص کنید کدام نوع Regularization (مانند L1 یا L2) مناسب‌تر است و دلایل انتخاب خود را به‌صورت مستند توضیح دهید.

منابع برای مطالعه بیشتر:

<https://towardsdatascience.com/understanding-l1-l2-regularization-part-1-9c7affe6f920>

<https://www.simplilearn.com/tutorials/machine-learning-tutorial/regularization-in-machine-learning>